Génération multimodale et multilingue de textes FALC

Sélian Arsène
selian.arsene@etu.unicaen.fr

Sofiene Chebana
sofiene.chebana@etu.unicaen.fr

Abstract

L'accessibilité à l'information, au-delà des simples normes numériques, représente un levier essentiel de l'autonomie citoyenne pour les personnes présentant des troubles de la compréhension ou des difficultés linguistiques. C'est dans ce cadre que s'inscrivent les directives européennes du Facile à Lire et à Comprendre (FALC). Néanmoins, l'automatisation de la simplification textuelle se heurte à la rareté des corpus spécialisés ainsi qu'à l'absence de solutions intégrant les dimensions multilingues et multimodales. Ce projet présente le développement d'un pipeline de génération de documents FALC s'appuyant sur une architecture de type Encoder-Decoder (T5-small et T5-base). Contrairement aux approches extractives classiques, nous proposons une méthode de simplification abstractive "Translate-and-Simplify", permettant le traitement de documents multilingues tout en centralisant l'intelligence du modèle sur un fine-tuning spécifique en langue française. Nos résultats démontrent qu'un arbitrage entre la convergence sémantique (Loss) et la capacité de reformulation (Novelty) permet d'atteindre un indice de lisibilité de Flesch de 92,84, garantissant une réduction drastique de la charge cognitive. Le code est disponible publiquement sur notre dépôt Git.

1 Introduction

Le FALC, acronyme de "Facile A Lire et à Comprendre", est une méthode qui a pour but de traduire un langage classique en un langage simplifié. Le FALC permet de rendre l'information plus simple et plus claire, la rendant ainsi accessible à tout le monde, notamment aux personnes en situation de handicap, dyslexiques, âgées ou bien maîtrisant mal la langue française.

Cette méthode peut être utilisée par tout le monde. Pour qu'un texte ou tout support de communication soit FALC, il doit avoir été lu et compris par des personnes en situation de handicap intellectuel. Un texte ayant été reconnu FALC a par ailleurs la possibilité d'y apposer un logo certificatif. Aujourd'hui, une version FALC de certains documents importants, comme par exemple les professions de foi de candidats politiques, sont rendus obligatoires dans certains pays.



Figure 1: Logo certifiant qu'un texte est FALC.

L'enjeu du FALC s'inscrit dans une démarche de justice sociale et d'accessibilité universelle. Il constitue levier d'autonomie citoyenne, permettant à chaque individu de s'orienter et de décider par lui même. Il agit également en tant que réponse pertinente face à l'exclusion cognitive et linguistique. En effet, le FALC ne s'adresse pas uniquement aux personnes en situation de handicap intellectuel, mais aussi à une large partie de la population, comme les personnes dyslexiques, les personnes âgées ou encore les publics allophones.



Figure 2: Exemple de simplification d'un texte en texte FALC

Avant d'aborder l'aspect technique de la génération multilingue de textes FALC, il faut dans un premier temps définir précisément ce qu'est un support d'information FALC. Un support d'information est dit Facile A Lire et à Comprendre s'il respecte un ensemble de 40 règles regroupées en 4 catégories. La première catégorie est la rédaction (le fond). Il faut éviter les mots complexes et favoriser l'utilisation de mots fréquemment utilisés. La seconde catégorie concerne la mise en page. Elle impose l'utilisation de polices de caractères sans empattement (type Arial ou Helvetica), une taille de texte minimale (souvent 12 ou 14 points), un interlignage aéré et l'alignement du texte à gauche

(le ferrage à gauche) pour éviter les espaces irréguliers entre les mots qui perturbent la lecture.

Une autre catégorie à prendre en compte est le visuel. Le FALC exige que le message soit soutenu par des images ou des pictogrammes. Ces visuels doivent être placés à côté du texte qu'ils illustrent et être d'une grande clarté sémantique. Ils ne servent pas de décoration mais de leviers de compréhension, permettant à l'utilisateur de valider visuellement le sens des mots écrits.

2 État de l'art

2.1 Génération de textes

Nous nous permettons ici une petite digression concernant l'histoire de la génération de textes et notamment des différentes architectures qui se sont succédées.

Durant les prémices de la génération de texte, une approche symbolique à base de systèmes à règles était utilisé. Des linguistes écrivaient des milliers de lignes de règles de type SI (Sujet + Verbe) ALORS (Chercher Complément). L'inconvénient majeur de cette approche est la complexité des langues qui sont pleines d'exceptions. De tels systèmes s'effondraient dès que la phrase sortait du cadre prévu.

Les modèles N-grammes ont ensuite tenté une approche stochastique qui se rapprochent du concept des chaînes de Markov [8]. Le but étant de calculer la probabilité d'un mot (d'un état futur) sachant le mot situé avant (l'état courant). Cette façon de faire permettait d'avoir des phrases cohérentes localement mais dont le sens se perdait au niveau global.
Les réseaux de neurones récurrents (Recurrent Neural Network[RNN][6] en anglais) sont arrivés suivis des Long Short Term Memory[LSTM][2]. L'arrivée de ces deux architectures ont permis de traiter le texte comme une suite logique de mots. Cependant, ces 2 architectures souffrent de problèmes importants. Tout d'abord, pour les RNN, bien qu'ayant réussi à introduire un mécanisme de mémoire au sein du système afin de mieux comprendre le contexte des mots, l'intérêt de celui-ci se retrouve parfois limité si un mot permettant de donner du contexte est situé trop loin d'un autre mot qui en a besoin dans le texte.
Les LSTM tentent de contrer ce problème en introduisant une cellule de mémoire complexe dotée de mécanismes de filtrage appelés portes (gates). Grâce à trois composants clés: la forget gate, l'input gate, et l'output gate, le modèle est capable de décider mathématiquement quelles informations contextuelles doivent être conservées sur le long terme et lesquelles sont devenues obsolètes. Le deuxième problème auxquels les RNN et les LSTM doivent faire face sont les coûts computationnels importants. En effet, il n'est pas possible de d'effectuer une exécution parallèle de tels systèmes car ils traitent obligatoirement les phrases mot après mot, de gauche à droite.

La dernière architecture en date, les Transformers ont révolutionné le monde de la génération de texte. Originellement apparus pour la première fois en 2017 dans l'article scientifique **"Attention is all you need"[10]**, la popularité des Transformers a depuis explosé. Ces architectures introduisent le mécanisme de Self-Attention qui permettent aux modèles de ne plus avoir besoin de lire une phrase mot après mot. Cela permet ainsi une parallélisation massive des calculs, entraînant un gain de temps conséquent. Ce sont également de ces architectures que sont issus les modèles que nous utilisons pour nos travaux.

2.2 Travaux connexes

Pour nos recherches sur la génération de textes FALC, nous avons découvert les travaux de François Ledoyen et al. sur la génération de textes inclusifs facile à lire [3], qui porte sur la création d'un dataset français, ETR-fr, respectant les règles FALC afin de générer une version FALC d'un texte en français. On retrouve dans cet article l'approche utilisée pour créer un dataset français d'exemples de textes FALC. Il s'agit d'un corpus de 523 paires de paragraphes (texte original vs FALC) extraits de la collection de livres "Facile à lire" des Edtitions François Baudez, ainsi que l'utilisation d'un modèle mBARThez pour la partie génération de textes. Puisqu'il y a peu de données FALC, le modèle a plusieurs tâches. Il va dans un premier temps résumer le texte, puis simplifier ce dernier pour ensuite générer la version FALC. Le but de cette approche est d'apprendre au modèle qu'un texte FALC doit être court et simple. Ce système fonctionne très bien pour des textes littéraires, mais rencontre des difficultés si on s'en éloigne (comme des textes administratifs, juridiques). Il demande aussi d'importantes ressources (Mistral-7B, LlaMA-3-8B), coûtant beaucoup d'énergie et demandant des serveurs puissants. Une autre avancée notable est l'approche multi-tâches proposée par [4], qui explore l'utilisation des grands modèles de langage (LLMs) pour la génération de textes Facile à Lire et à Comprendre. Dans ces travaux, la simplification n'est pas traitée comme une conversion isolée, mais comme un processus global intégrant le résumé et la simplification syntaxique. Cependant, alors que ces travaux se concentrent principalement sur l'efficacité de la génération textuelle en français, notre projet étend cette réflexion à une dimension multilingue et multimodale. Là où l'approche multi-tâches classique optimise la structure grammaticale, notre pipeline "Translate-and-Simplify" assure une accessibilité universelle tout en intégrant l'ancrage visuel automatique par pictogrammes.

A ce jour, on note, malgré des travaux scientifiques convaincant concernant la génération de textes FALC, un manque flagrant de recherches et d'approches dans le domaine multilingue et multimodale. On constate également une pénurie de corpus parallèles multilingues (textes sources appariés à leurs versions simplifiées), ce

qui limite l'entraînement de modèles robustes hors du monde anglophone.

3 FALC multilingue

Dans le cadre de notre projet, nous nous sommes intéressés à l'aspect multilingue de la génération de documents FALC. L'enjeu est de pouvoir générer une version FALC d'un document, et ce quel que soit la langue dans laquelle le document est originellement rédigé. Pour ce faire, une solution serait un modèle capable de générer du FALC quel que soit la langue. Néanmoins, un obstacle majeur est la quantité et la diversité de données que cette approche implique. De plus, comme évoqué dans **"Multilingual Text Simplification: A Survey"[7]**, il est important de constater la rareté des données concernant cette tâche dans de nombreuses langues. Ainsi, un modèle entraîné majoritairement sur une langue peut développer des biais propres à cette langue qu'il peut réutiliser à tort sur d'autres. Une autre solution est la mise en place d'une chaîne de traitement (pipeline) qui possède une structure en trois temps :

1. **Traduction en français du texte en entrée.**
2. **Génération du document FALC correspondant.**
3. **Traduction du document FALC français vers la langue d'origine.**

De cette manière, le modèle conserve un apprentissage exclusivement à partir de données en français, ce qui l'oriente vers des performances stables. Cette approche par « pipeline » de traduction permet de contourner l'absence de corpus parallèles massifs dans des langues moins dotées que le français. En isolant l'étape de simplification au sein d'une langue pivot maîtrisée par le modèle, on réduit considérablement le risque d'hallucinations syntaxiques qui surviennent souvent lors de transferts linguistiques directs. Toutefois, cette méthode en trois étapes introduit une problématique de propagation d'erreurs. Une nuance mal interprétée lors de la traduction initiale vers le français peut être amplifiée durant la phase de simplification par T5, rendant la traduction finale vers la langue d'origine potentiellement inexacte ou éloignée du sens premier.
Pour atténuer ce risque, il est crucial de s'appuyer sur des outils de traduction neuronale performants en amont et en aval de la chaîne de traitement. L'enjeu technique réside alors dans la préservation des marqueurs de simplicité lors de la dernière étape : le traducteur doit être capable de conserver le vocabulaire restreint et les structures de phrases courtes générées par le modèle FALC, sans réintroduire de complexité littéraire dans la langue cible. Cette stratégie, bien que plus lourde en temps de calcul, semble être la solution la plus viable à court terme pour offrir un service d'accessibilité universel, en attendant l'émergence de modèles multilingues natifs entraînés sur des corpus simplifiés diversifiés.

4 FALC multimodal

La génération de documents FALC ne repose pas seulement que sur du texte. Les images, l'audio ont une place importante dans l'accessibilité du document. Pour ce faire, on propose d'analyser une phrase afin de détecter automatiquement des mots à haute charge informative. En isolant les termes essentiels à la compréhension globale de la phrase, nous pouvons générer des supports visuels ciblés qui servent de points d'appui cognitifs, réduisant ainsi la charge mentale nécessaire à la lecture.
Avant de savoir si un mot est important, le modèle doit comprendre sa nature. Est-ce un nom, un verbe, une adjonction ou un "mot-outil" (le, de, du) ? Pour le FALC, On sait que les noms et les verbes d'action sont les pivots du sens. Les déterminants et les prépositions sont souvent secondaires pour l'illustration. On s'appuie également sur la reconnaissance d'entités nommées car ces dernières sont généralement pertinentes à imager. Afin d'extraire les mots importants d'une phrase, on peut s'aider de techniques déja connue dans la littérature comme tout d'abord le score TF-IDF (Term Frequency-Inverse Document Frequency) [9] qui attribue un score à chaque mot d'une phrase, un score haut reflétant la rareté et le caractère unique d'un mot, et inversement pour un score bas. On peut également utilisé le TextRank [5], algorithme adapté du célébre PageRank qui permet dans notre contexte de créer un graphe dont les sommets sont les mots d'une phrase et dont les mots avec le plus de liaisons sont désignés comme mots importants.
Toutefois, l'accessibilité ne se limite pas à l'identification des mots-clés ; elle dépend tout autant de la structure spatiale dans laquelle ils s'insèrent. Une fois les pivots sémantiques isolés et illustrés, la mise en page doit elle-même guider l'œil et segmenter l'effort de lecture.

À cet égard, le saut de ligne systématique après la ponctuation augmente certes la consommation de papier, mais il réduit drastiquement la fatigue visuelle et la charge cognitive. C'est un choix délibéré d'ergonomie cognitive qui prime sur l'économie de place, afin de garantir le droit à l'information.

5 Détails d'implémentation

L'implémentation de notre générateur de textes FALC repose sur un réglage fin complet (**Full Fine-Tuning**) qui met à jour l'ensemble des paramètres du modèle. Cette stratégie est particulièrement adaptée à l'adaptation de modèles de langage pré-entraînés sur des domaines très spécifiques comme l'accessibilité cognitive, car elle permet de modifier un sous-ensemble restreint de poids, limitant ainsi les besoins en ressources de calcul et prévenant le phénomène d'oubli catastrophique des connaissances linguistiques générales. Dans ce cadre, nous avons sélectionné et comparé les architectures T5-small et T5-base, dont la structure encodeur-décodeur est naturellement optimisée pour

les tâches de transformation de texte à texte.

5.1 Corpus de données et stratégie d'enrichissement

L'entraînement de nos modèles s'appuie prioritairement sur le corpus ETR-fr [3], une ressource spécialisée dans la simplification pour les troubles cognitifs. Ce dataset bénéficie d'un prétraitement standardisé — incluant normalisation textuelle et segmentation à 512 tokens — ce qui garantit une base d'apprentissage stable et cohérente. Toutefois, si ce corpus assure la qualité des structures FALC, son périmètre thématique restreint peut limiter la capacité du modèle à généraliser ses compétences de simplification à des domaines variés de la vie quotidienne ou institutionnelle.
Pour pallier cette spécialisation et renforcer la polyvalence de l'architecture T5, nous avons pris l'initiative de concevoir un dataset complémentaire semi-synthétique via une ingénierie de requêtes ciblée sur l'agent Gemini. Cette extension a été structurée autour de plusieurs piliers thématiques afin d'injecter une plus grande diversité lexicale dans le processus de fine-tuning. Un premier axe a été consacré au discours politique et citoyen à travers le traitement des professions de foi des candidats à l'élection présidentielle française de 2022. Ces documents, caractérisés par une forte densité sémantique et des structures rhétoriques complexes, constituent un cas d'étude idéal pour tester la capacité du modèle à extraire l'essentiel d'un message sans en altérer l'information.
En parallèle, nous avons étendu cet enrichissement à des domaines plus ancrés dans le quotidien, tels que le sport et la nature. La transformation de ces textes en versions FALC a été réalisée par une phase de prompt engineering visant à simuler rigoureusement le format « source-cible » du dataset ETR-fr. En imposant des contraintes strictes lors de la génération — telles que l'usage d'un vocabulaire courant, la brièveté des phrases et la suppression systématique des métaphores complexes — nous avons pu confronter le modèle à des descriptions plus concrètes. Cette diversification permet au générateur de ne plus se restreindre à un style purement administratif ou littéraire, tout en testant sa viabilité sur des documents citoyens réels là où les données d'entraînement classiques font souvent défaut.

5.2 Pictogrammes

La simplification FALC ne serait être complète sans un support visuel, le texte seul étant parfois insuffisant pour garantir une accessibilité totale. Pour répondre à cette exigence multimodale, nous avons intégré l'API ARASAAC [1], une ressource de référence proposant des pictogrammes conçus spécifiquement pour l'accessibilité universelle. Le processus technique d'intégration commence par une analyse lexicale de la phrase simplifiée par le modèle T5 afin d'en extraire les concepts pivots, tels que les sujets et les verbes d'action.

Ces concepts font ensuite l'objet d'une requête auprès de l'API espagnole, ce qui nécessite une gestion fine de l'ambiguïté sémantique pour garantir que l'image sélectionnée correspond au contexte précis de la phrase. Le système final génère alors un document hybride où chaque segment de texte simplifié est associé à son équivalent visuel. Cette structure bicéphale permet de réduire drastiquement la charge cognitive nécessaire au traitement de l'information par l'utilisateur final. Enfin, il convient de noter que l'utilisation de la librairie ARASAAC impose une mention explicite sur tout document produit, ce que nous avons fait, respectant ainsi les conditions de licence de cette ressource libre d'utilisation.

5.3 Paramètres du modèle

Le choix des hyperparamètres d'entraînement a été guidé par la nécessité de trouver un équilibre entre la convergence sémantique et la prévention du surapprentissage (overfitting), particulièrement critique compte tenu de la taille restreinte des datasets. Comme le montre le tableau 1, un taux d'apprentissage plus élevé (0.001) pour le modèle *small*, a été privilégié. Les modèles compacts possèdent moins de paramètres et ont tendance à nécessiter des mises à jour de poids plus importantes pour s'extraire de minima locaux et apprendre efficacement les règles de simplification FALC. A l'inverse, le modèle *base* a été entraîné avec un taux d'apprentissage plus fin (0.00005). Les architectures plus larges sont plus sensibles aux instabilités du gradient et un taux d'apprentissage trop élevé risquerait de détruire les connaissances pré-entraînées (phénomène de *catastrophic forgetting*).

Quant au choix du planificateur, le planificateur Cosinus a été choisi pour les deux modèles, permettant une décroissance fluide du taux d'apprentissage tout au long de l'entraînement. Cette stratégie favorise une convergence plus précise vers un minimum global, évitant les oscillations brutales de la fonction de perte. Concernant au choix du nombre d'époques, la différence du nombre d'époques entre le modèle *base* (5) et le modèle *small* (15) s'explique par la différence de taille des modèles, *base* possède plus de paramètres, ce qui lui permet de comprendre les règles FALC plus rapidement que le *small*. Enfin, la taille de lot (*batch size*) a été fixée à 8 pour les deux modèles afin d'optimiser l'utilisation de la mémoire GPU disponible tout en maintenant une estimation robuste du gradient à chaque itération.

6 Métriques de transformation textuelle

Score ROUGEs
Les score ROUGE mesurent la similitude entre 2 phrases. Contrairement à des tâches de traductions, avoir un score ROUGE bas en simplification de textes est plutôt positif. En effet, cela traduit une faible superposition lexicale entre le texte d'origine et le texte simplifié.
Nous utilisons trois variantes de la métrique ROUGE : ROUGE-1, ROUGE-2 et ROUGE-L. ROUGE-1 et ROUGE-2 mesurent respectivement le recouvrement

des unigrammes et des bigrammes entre le texte d'origine et le texte simplifié, ce qui permet d'évaluer la similarité lexicale. ROUGE-L, quant à lui, s'appuie sur la plus longue sous-séquence commune (LCS) entre deux textes, ce qui permet de mesurer la similarité structurelle et le respect de l'ordre des idées.

$$\text{ROUGE-L} = \frac{\sum_{\text{réf} \in R} \text{LCS}(\text{hyp}, \text{ref})}{\sum_{\text{réf} \in R} |\text{ref}|}$$

où :

- hyp correspond au texte FALC généré pendant l'entrainement (Hypothesis summary)
- ref correspond dans notre contexte au texte d'entrée non simplifié (Reference)

Indice de lisibilité Flesch
L'indice de lisibilité de Flesch (ou Flesch Reading Ease) est une métrique statistique utilisée pour évaluer la complexité d'un texte. Dans le cadre de notre projet, cet indicateur est crucial car il permet de valider mathématiquement la réussite de la simplification FALC. Le score repose sur une formule qui combine la longueur des phrases et la complexité des mots (nombre de syllabes) :

$$\text{FRES} = 206.835 - 1.015 \left(\frac{W}{X} \right) - 84.6 \left(\frac{S}{W} \right)$$

où :

- W est le nombre de mots.
- X est le nombre de phrases.
- S est le nombre de syllables.

Plus le score est élevé, plus le texte est considéré comme simple à lire. Un texte très difficile se situe généralement entre 0 et 30 tandis qu'un texte facile à lire se situe plus souvent entre 70 et 100.

7 Résultats

Le tableau 3 synthétise les performances de nos deux architectures après optimisation du nombre d'époques (5 pour T5-base, 15 pour T5-small).

7.1 Analyse des performances du modèle T5-base

Les résultats obtenus à la 5ème époque de l'entraînement démontrent une convergence efficace du modèle vers les objectifs FALC :

Lisibilité (Flesch) : L'indice de *Flesch Reading Ease* atteint **74.41**. Ce score confirme que les textes générés se situent dans la catégorie « Facile à lire », marquant une nette amélioration par rapport au texte source. On note également que les scores **ROUGEs** atteignent des niveaux très bas. Cela est plutôt positif, en effet, cela traduit une faible superposition lexicale entre le texte d'origine et le texte simplifié. Cela montre que peu de mots employés par les textes d'origines sont réutilisés dans les textes FALC résultants. **Qualité de l'apprentissage** : La *Validation Loss* se stabilise à **0.72**. Ce résultat indique que le modèle a capté la logique de simplification sans tomber dans le surapprentissage (*overfitting*) excessif.

Efficacité : La rapidité de traitement (7.24 échantillons/sec) permet d'envisager une utilisation en temps réel pour la simplification de documents administratifs ou narratifs.

7.2 Analyse des performances du modèle T5-small

L'évolution des performances du modèle *T5-small* entre l'époque 5 (score de 74.41) et l'époque 15 (score de 104.45) constitue l'un des enseignements majeurs de notre projet.

Le score de Flesch de **104.45** indique que le modèle a fini par franchir un seuil de compétence linguistique. Après une phase initiale de latence, il parvient désormais à produire des structures conformes au FALC (niveau « Très Facile »).

Les scores ROUGE du modèle T5-small sont relativement semblables avec ceux de T5-base comme le montre le tableau .

Contrairement au modèle *base* qui converge rapidement, le modèle *small* nécessite un entraînement plus long (15 époques) pour stabiliser sa génération. La *loss* à **0.28** confirme que le taux d'apprentissage plus élevé n'a pas conduit à une dégradation sémantique, mais à une meilleure maîtrise syntaxique.

Efficacité et Légèreté (15.85 échantillons/sec)
C'est ici que le modèle *small* surpasse la version *base* : il est deux fois plus rapide à l'inférence. Avec un score de lisibilité équivalent, il devient la solution optimale pour un déploiement sur des infrastructures légères.

8 Exemples de sorties multimodales (ARASAAC)

L'intégration des pictogrammes suit une logique d'ancrage visuel sur les lexèmes à forte charge sémantique identifiés par le modèle.

9 Limites et perspectives

L'utilisation de modèles de langage tels que T5 pour la simplification FALC soulève également la question critique de la fidélité de l'information. En dépit de leurs performances, ces architectures restent sujettes au phénomène d'hallucinations, où le modèle génère des informations factuellement erronées ou sémantiquement incohérentes avec le texte source. Dans le cadre du FALC, une telle dérive est particulièrement problématique, car elle peut altérer le sens d'une consigne de sécurité ou d'un droit administratif.

À l'heure actuelle, le manque de corpus de données réels et diversifiés limite notre capacité à évaluer si ces erreurs sont des cas isolés ou des biais systématiques. En l'état, il est difficile de confirmer si l'architecture

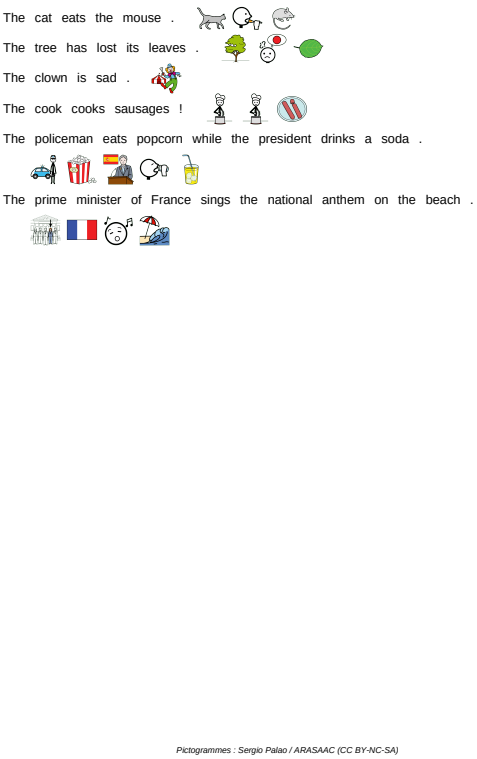


Figure 3: Exemple de texte simple en anglais avec insertion automatique de pictogrammes ARASAAC.

T5 constitue une solution viable et sécurisée sur le long terme sans l'ajout d'un mécanisme de contrôle rigoureux. Cette incertitude souligne la nécessité de poursuivre la constitution de jeux de données authentiques afin de mesurer plus précisément la fiabilité de ces modèles avant toute mise en production. Bien que notre pipeline actuel soit limité au français et à l'anglais, une évolution majeure résiderait dans une approche multilingue et multimodale universelle via l'utilisation de **jetons spéciaux** (*special tokens*). Dans un processus de traduction classique, les modèles ont tendance à omettre ou déformer les éléments non linguistiques. En introduisant des jetons spéciaux (ex: `<PIC_ID_125>`) directement dans le vocabulaire du modèle de traduction et du moteur de simplification, nous créons des **points d'ancrage sémantiques invariants**. Ces jetons agissent comme des "passeports" visuels : le modèle de traduction apprend à les conserver et à les déplacer de manière cohérente selon la syntaxe de la langue cible, sans en altérer le contenu numérique. Cette méthode permettrait de pallier l'incapacité de l'API ARASAAC à reconnaître certaines langues sources en effectuant un mapping direct entre l'identifiant du jeton et le dictionnaire de pictogrammes stocké localement. Une telle architecture rendrait le traitement non seulement plus robuste face aux hallucinations linguistiques, mais aussi nettement plus rapide en limitant les requêtes API redondantes.

Par ailleurs, une perspective d'amélioration technique consisterait à intégrer des contraintes de décodage strictes (*Constrained Beam Search*) pour garantir le respect systématique des normes FALC. Si la brièveté des phrases (idéalement entre 10 et 15 mots) est aujourd'hui induite par le *fine-tuning* et la pénalité de longueur, un contrôle algorithmique permettrait de certifier la conformité structurelle de chaque sortie, rendant la génération de texte multimodal plus rapide, robuste et sécurisée.

Enfin, bien que les documents produits respectent les contraintes structurelles du FALC (brièveté des phrases, lexique simplifié), il convient de souligner une limite méthodologique majeure : l'absence de validation par un comité de relecture composé de personnes en situation de handicap intellectuel. Conformément aux directives européennes, cette étape est indispensable pour garantir l'accessibilité réelle et obtenir le label officiel. Ce projet se définit donc comme une architecture de **génération assistée de documents FALC**. L'architecture proposée sert de **support à la production sémantique** ; elle délègue au modèle la charge de simplification textuelle, réservant la validation de la cohérence finale à l'expertise des comités de relecture.

Conclusion intermédiaire : Le modèle *T5-small*, bien qu'initialement instable, s'est révélé extrêmement performant après un réglage fin de la durée d'entraînement. Il offre le meilleur compromis entre **compacité technique** (faible nombre de paramètres) et **qualité de simplification**.

10 Conclusion

Ce projet a permis de démontrer la faisabilité d'un pipeline automatisé pour la génération de documents FALC (Facile À Lire et à Comprendre), intégrant pour la première fois une approche à la fois multilingue et multimodale. À une époque où l'accès à l'information est devenu un enjeu stratégique, garantir à chacun une compréhension équitable des contenus n'est plus une option, mais une nécessité. En plaçant l'accessibilité cognitive au cœur des innovations technologiques, le FALC s'affirme comme un véritable pilier social et démocratique, indispensable à l'exercice d'une citoyenneté pleine et entière pour tous.

10.1 Synthèse des contributions

Performance technique : L'utilisation d'architectures Encoder-Decoder (T5) via une stratégie **Full Fine-Tuning** a prouvé son efficacité. Le modèle T5-small, après un réglage fin de 15 époques, offre le meilleur compromis avec un indice de lisibilité de Flesch de 92,84 (niveau "Très Facile") tout en étant deux fois plus rapide à l'inférence que la version base.

Levée du verrou linguistique : La méthode "Translate-and-Simplify" permet de contourner la pénurie de corpus parallèles dans les langues autres que le

français, garantissant une stabilité des performances en centralisant l'intelligence du modèle sur un fine-tuning spécifique.

Apport multimodal : L'intégration de l'API ARASAAC transforme le texte simplifié en un support hybride. En utilisant des techniques d'extraction comme le score TF-IDF ou TextRank, le système identifie les pivots sémantiques (noms et verbes d'action) pour y ancrer des pictogrammes, réduisant ainsi la charge cognitive de l'utilisateur.

Malgré ces résultats encourageants, la persistance de phénomènes d'hallucinations sémantiques dans les modèles de type T5 nécessite la mise en place de mécanismes de contrôle de fidélité rigoureux avant toute application réelle, notamment dans les domaines administratifs ou juridiques.

L'avenir de ce projet réside dans l'enrichissement des jeux de données authentiques et l'exploration de modèles de plus grande taille, si les ressources computationnelles le permettent, afin de minimiser ces dérives factuelles tout en maintenant l'accessibilité universelle au cœur du dispositif.

Cette annexe présente l'intégralité des métriques obtenues lors des phases de fine-tuning des modèles T5-small et T5-base.

Table 1: Comparaison des hyperparamètres d'entraînement

Paramètre	**T5-small**	**T5-base**
Nombre d'époques	15	5
Taux d'apprentissage	**1e-3**	**5e-5**
Planificateur	Cosinus	Cosinus
Taille de lot	8	8

Table 2: Paramètres de génération

Paramètre	**T5-small**	**T5-base**
Pénalité de répétition	2.5	
Pénalité de longueur	0.5	
Taille n-gram de non-répétition	2	
Nombre de faisceaux	2	

Table 3: Synthèse des résultats : T5-base vs T5-small

Modèle	**Flesch**	**Loss**	**Vitesse***
T5-base (Ep. 5)	74.41	**0.72**	7.24
T5-small (Ep. 15)	**104.45**	0.28	**15.85**

*Vitesse exprimée en échantillons par seconde.

Table 4: Synthèse des résultats ROUGE : T5-base vs T5-small

Modèle	**ROUGE-1**	**ROUGE-2**	**ROUGE-L**
T5-base (Ep. 5)	**0.11**	**0.02**	**0.08**
T5-small (Ep. 15)	0.13	0.03	0.11

*Vitesse exprimée en échantillons par seconde.

References

[1] Centro Aragonés de la Comunicación Aumentativa y Alternativa (ARASAAC). 2024. Aragonese portal of augmentative and alternative communication. Accessed: 2026-02-23.

[2] Sepp Hochreiter and Jürgen Schmidhuber. 1997. Long short-term memory. In *Neural computation*, volume 9, pages 1735–1780. MIT Press.

[3] François Ledoyen, Gaël Dias, Alexis Lechervy, Jérémie Pantin, Fabrice Maurel, Youssef Chahir, and 1 others. 2025. Inclusive easy-to-read text generation for individuals with cognitive impairments. *arXiv preprint arXiv:2510.00691*.

[4] François Ledoyen, Gaël Dias, Jérémie Pantin, Alexis Lechervy, Fabrice Maurel, and Youssef Chahir. 2024. Facilitating cognitive accessibility with llms: A multitask approach to easy-to-read text generation. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 11568–11587, Bangkok, Thailand. Association for Computational Linguistics.

[5] Rada Mihalcea and Paul Tarau. 2004. Textrank: Bringing order into text. In *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 404–411.

[6] David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. 1986. Learning representations by back-propagating errors. In *nature*, volume 323, pages 533–536. Nature Publishing Group.

[7] Horacio Saggion. 2017. Multilingual text simplification: A survey. *Journal of Artificial Intelligence Research / ArXiv*.

[8] Claude Elwood Shannon. 1948. A mathematical theory of communication. In *The Bell system technical journal*, volume 27, pages 379–423. Nokia Bell Labs.

[9] Karen Spärck Jones. 1972. A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*, 28(1):11–21.

[10] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 5998–6008.